Proyecto Final Machine Learning 2026

Adriana Lorenzo Mingorance
Universidad Pontifica Comillas
Machine Learning, 2º B iMAT

202314429@alu.comillas.edu

Abstract

Este trabajo presenta un estudio completo de aprendizaje automático sobre un conjunto de datos 4424 estudiantes de eduación superior, con el objetivo de comprender los factores asociados al éxito y abandono académico. Se abordan 3 tareas complementarias: clasificación de la situación final del estudiante (abandono, matriculado, graduado); regresión para predecir la clasificación media del segundo semestre; y clustering para identificar perfiles de riesgo. Analizamos a su vez el impacto de variables demográficas y socieconómicas, entre otros factores.

1 Introducción

El abandono universitario representa uno de los principales retos de las instituciones de educación superior, con implicaciones académicas, económicas y sociales significativas. La disponibilidad de datos administrtivos y académicos hace posible abordar este problema mediante técnicas de aprendizaje automático, con el objetivo de anticipar trayectorias y orientar la toma de decisiones institucional.

En este trabajo analizamos un conjunto de datos con informacioón de **4.424 estudiantes** de educación superior portuguesa, que incluye variables demográficas, socieconómicas, de acceso universitario y de rendimiento académico en el primer y el segundo semestre. La variable objetivo distingue tres clases: *abandono*(32.1%), *matriculado* (17.9%) y *graduado* (49.9%).

Planteamos el análisis desde tres perspectivas complementarias. En primer lugar, se aborda una tarea de **clasificación supervisada** para predecir la situación final del estudiante (Sección 4).

En segundo lugar, desarrollamos una tarea de **regresión** para anticipar la nota emdia del segundo semestre, prestando especial atención a evitar problemas de fuga de información (Sección 5). Finalmente, aplicamos **aprendizaje no supervisado** mediante técnicas de clustering para identificar perfiels de estudiantes y analizar su relación con la trayectoria académica (Sección 6).

Más allá del rendimiento predictivo, el objetivo del trabajo es identificar los factores más relevantes asociados al éxito o abandono académico, así como evaluar la capcidad de los modelos para capturar patrones útiles en un contexto educativo real.

2 Exploración de datos (EDA)

El dataset contiene 4424 instancias y 37 variables organizadas en seis bloques: demográficas y personales, de acceso y contexto académico previo, socioeconómicas y administrativas, macroeconómics, y de rendimiento en primer y segundo semestre. No hemos detectado valores nulos en ninguna variable.

La variable objetivo presenta un desbalanceo moderado (ratio 2.8x entre clase mayoritaria y minoritaria), lo que se tiene en cuenta en la evaluación de modelos mediante F1 macro y el parámetro `class_weight='balanced'`

2.1 Variables y relaciones clave

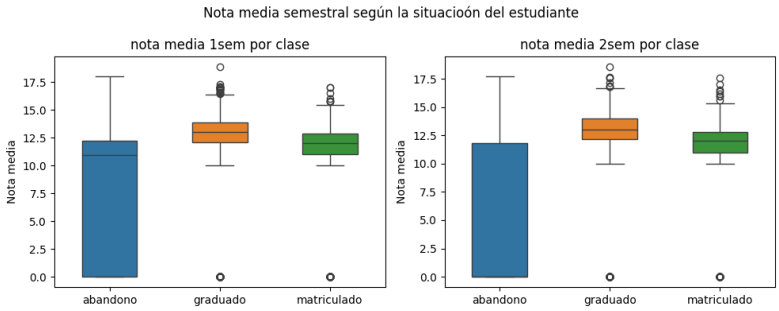


Figure 1: Nota media semestral según situación del estudiante.

Los graduados presentan notas medias significativamente superiores en ambos semestres; mientras que los estudiantes con abandono concentran sus valores en torno a cero, indicando que muchos no llegan a evaluarse.

Destacamos que la mediana de `nota_media_2sem` para el grupo de abandono es exactamente 0.0, confirmando que al menos la mitad de estos estudiantes no llegan a examinarse en el 2º semestre.

El análisis exploratorio revela que las variables de rendimiento del primer semestre (especialmente `nota_media_1sem` y `asignaturas_1sem_aprobadas`) presentan la mayor correlación con la variable objetivo y con la nota del segundo semestre ($r = 0.84$). Además, las variables socieconómicas como matrícula al día, becado y deudor muestran una asociacion clara con la situación final del estudiante. Hemos incluido más gráficas y un análisis más profundo en el notebook 1.

3 Preprocesado de datos y decisiones metodológicas

3.1 Codificación de variables categóricas

Las variables categóricas del dataset (estado civil, modo de solicitud, curso, nacionalidad, cualificación y ocupación de progenitores, entre otras) se han codificado mediante *One-Hot Encoding*, tal y como hemos estudiado, lo que expande el espacio de features de 37 a 237 dimensiones para clasificación y a 232 para regresión. Esta decisión es coherente con el uso de modelos que no asumen linealidad ni orden en las categorías. Como consecuencia, veremos más adelante que la Regresión Lineal ordinaria resulta inviable por multicolinealidad perfecta entre columnas dummy, lo que motiva el uso de Ridge y Lasso como alternativas regularizadas en la tarea de regresión.

3.2 Exclusión de variables por *data leakage*

En la tarea de regresión excluímos todas las variables del segundo semestre contemporáneas al target (`nota_media_2sem`): asignaturas matriculadas evaluadas, aprobadas, sin evaluación y convalidadas del segundo semestre. Su inclusión constituiría una fuga de información, ya que estas variables se registran simultáneamente con la nota que se desea predecir. El espacio de predictores queda así en 232 features, basados exclusivamente en información previa al segundo semestre.

3.2.1 División train/test y escalado

Previamente a la división, lo primero que hacemos es permutar los datos aleatoriamente (en este caso lo hemos realizado con semilla 42) para eliminar cualquier orden sistemático en el dataset. Utilizamos una división estratificada 80/20, preservando la proporción de clases en ambos conjuntos. El escalado mediante `StandardScaler` se aplica así exclusivamente sobre los datos de training (*fit* en train, *transform* en test), evitando así la fuga de información del escalado. Los modelos basados en árboles (Random Forest, Gradient Boosting) no requieren escalado y se entrenan directamente sobre los datos codificados. Hemos creado así distintos csv con los datos adecuados para cada tarea.

4 Tarea 1: Clasificación

En nuestra primera tarea, el objetivo es predecir la situación final del estudiante entre las tres clases posibles. Se trata así de un problema multiclase con un desbalanceo moderado (ratio 2.8x), por lo que hemos decidido emplear el F1 macro como métrica prinicipal, ya que penaliza por igual el mal rendimiento en clases minoritarias.

4.1 Modelos e implementación

Comparamos 4 modelos de complejidad creciente: Regresión Logísitca como baseline lineal, KNN (k=7, seleccionado por validación cruzada), Random Forest (200 árboles) y Gradient Boosting (200 estimadores, *learning rate* 0.1). Los modelos lineales se entrenan sobre datos escalados (cuyos datasets hemos obtenido en el notebook de preprocesado); los basados en árboles, sobre datos sin escalar. Todos incorporan `class_weight='balanced'` donde está disponible para mitigar el efecto del desbalanceo.

4.2 Resultados clasificación

Table 1: Comparativa de modelos de clasificación en el conjunto de test. F1 métrica principal por el desbalanceo de clases.

Modelo	Accuracy	F1 macro	Fº pond.
Regresión Logísitica	0.735	0.686	0.743
KNN (k=7)	0.603	0.478	0.566
Random Forest	0.773	0.685	0.752
Gradient Boosting	**0.764**	**0.690**	**0.755**

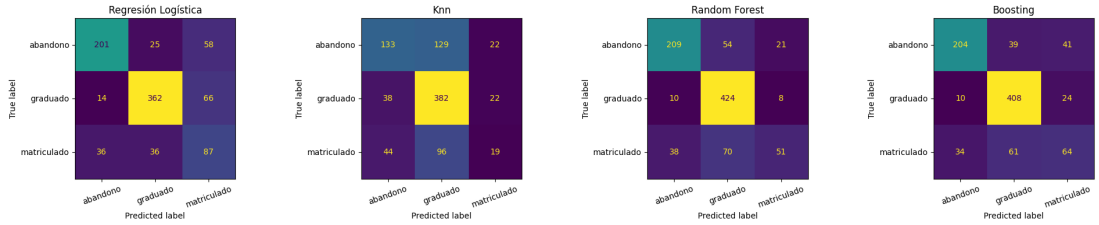


Figure 2: Matrices de confusión de los cuatro modelos.

La clase *matriculado* es sistemáticamente la más difícil de predecir en todos los modelos, como se analiza a continuación.

4.3 Análisis de resultados

Vemos como Gradient Boosting obtiene el mejor F1 macro (0.690), seguido muy cerca por Regresión Logística (0.686) y Random Forest (0.685). La similitud entre estos tres modelos sugiere que el problema tiene un techo de rendimiento natural ligero a la dificultad intrínseca de la tarea, más que a la capacidad del modelo.

KNN queda claramente por detrás (F1 macro 0.478), lo que es consistente con la *maldición de la dimensionalidad* estudiada en clase: con 237 features, las distancias euclídeas pierden capacidad discriminativa.

La clase *matriculado* presenta el menor F1 en todos los modelos (entre 0.43 y 0.47). Esto es esperable, ya que un estudiante "matriculado" es simplemente alguien que aún no ha terminado, sin un patrón académico consolidado, y complicado de predecir, lo que explica su solapamiento con ambas clases y su menor F1 en todos los modelos.

El solapamiento de *matriculado* con las otras clases explica su menor F1 en todos los modelos. Por otro lado, *abandono* (AUC = 0.91) y *graduado* son bien separables (AUC = 0.93); *matriculado*

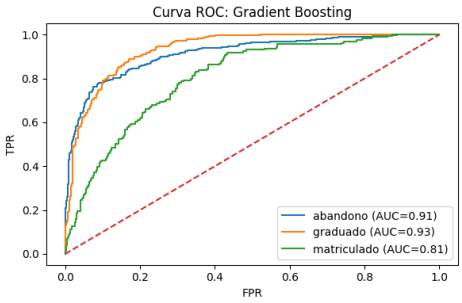


Figure 3: Curva ROC del mejor modelo (Gradient Boosting).

presenta mayor dificultad (AUC = 0.81) aprox, lo que es coherente con su solapamiento en las features.

Por último, en la sección 11 del notebook nos hemos centrado en analizar la importancia de las variables, comparando cómo asigna pesos RF vs Boosting. Ambos modelos coinciden en señalar `asignaturas_2sem_aprobadas` como la variable más relevante (RF con un peso de 0.11, y GB concentra más del 53% de su capacidad predictiva en esa única varible). Esto nos indica como superar el 2º semestre es determinante, ya que muchos de los que abandonan no llegan a examinarse en este, siendo el predictor más determinante de la situación final del estudiante.

5 Tarea 2 Aprendizaje supervisado: Regresión

El objetivo es predecir la nota media del estudiante en el segundo semestre (`nota_media_2sem`) a partir de información disponible antes de ese período. El target presenta una media de 10.23 puntos y una desviación típica de 5.21, con un 19.7% de valores iguales a cero, correspondientes a estudiantes que no llegaron a evaluarse (acorde a lo que hemos visto en el EDA).

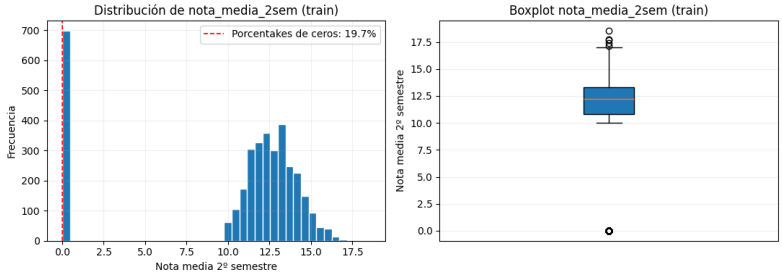


Figure 4: Distribución de `nota_media_2sem` en train

La línea roja marca la concentración de ceros (19.7%), correspondientes a estudiantes sin actividad evaluable en el segundo semestre.

5.1 Exclusión de variables y justificación metodológica

Las variables excluidas por *data leakage* son: `asignaturas_2sem_matriculadas`, `asignaturas_2sem_evaluadas`, `asignaturas_2sem_aprobadas`, `asignaturas_2sem_sin_evaluacion` y `asignaturas_2sem_convalidadas`; así como `objetivo`. Como hemos indicado en el notebook 4, hemos excluido las variables contemporáneas al target, ya que su inclusión permitiría al modelo ver información del semestre que queremos predecir. El espacio de predictores queda así en 232 features, basado en información de acceso, variables demográficas, socieconómicas y rendimiento del 1er semestre.

La regresión lineal ordinaria no es viable en este datsaset, ya que, como hemos mencionado, el One-Hot Encoding amplía el espacio a 232 features. Los coeficientes divergen y el modelo es

numéricamente inestable, como confirma la figura 5. Empleamos por tanto **Ridge y Lasso** como alternativas regularizadas, más apropiado metodológicamente en espacios de alta dimensión.

5.2 Modelos e implementación

Se comparan cinco modelos: **Regresión Lineal** como referencia no regularizada, el cual hemos dejado para evidenciar el problema de la multicolinealidad. **Ridge**($\alpha = 1.0$), que penaliza coeficientes grandes con regularización L2, resolviendo la inestabilidad. **Lasso** ($\alpha = 0.01$), que mediante L1 lleva algunos coeficientes a cero, haciendo selección automática de variables importantes. **Random Forest** (200 árboles) y **Gradient Boosting** (200 estimadores, *learning rate* 0.1) como modelos no lineales. Los modelos lineales se estrenan sobre datos escalados; los basados en árboles, sobre datos sin escalar.

5.3 Resultados

Table 2: Comparativa de modelos de regresión en el conjunto de test. Gradient Boosting obtiene el mejor equilibrio entre RMSE y R^2.

Modelo	RMSE	MAE	R^2	CV R^2
Regresión Lineal	—	—	$\ll 0$	—
Ridge	2.680	1.615	0.735	0.736 ± 0.035
Lasso	2.663	1.577	0.738	0.743 ± 0.036
Random Forest	2.733	1.397	0.724	0.768 ± 0.045
Gradient Boosting	**2.635**	**1.442**	**0.744**	$\mathbf{0.766 \pm 0.040}$

Incluímos validación cruzada (con 5 folds) sobre train. Vemos como la Regresión lineal explota, dándonos unos valores muy distintos del resto, reflejando su inaptitud para este dataset.

5.4 Análisis de resultados

La Figura 5 ilustra de forma clara la diferencia entre modelos. La RL produce predicciones fuera de escala, no vemos nada a penas. Al introducir Ridge o Lasso, la nube de puntos se concentra en torno a la diagonal, indicando buen ajuste general. La dispersión en valores bajos (en 0) refleja la dificultad de predecir notas de estudiantes con escasa actividad académica.

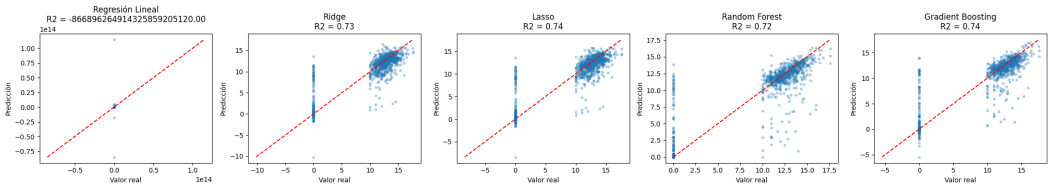


Figure 5: Predicciones vs. valores reales para los cuatro modelos.

.

La similitud entre los cuatro modelos viables (vemos cómo obtienen resultados similares: R^2 entre 0.72 y 0.74) sugiere que el límite de predicción está determinado por la información disponible más que por la capacidad del modelo. Un R^2 de 0.74 indica que el modelo explica el 74% de la varianza de la nota del segundo semestre a partir exclusivamente de información previa, lo cual es un resultado sólido.

El análisis de residuos del mejor modelo, GB, (Figura 6) muestra una distribución simétrica en torno a cero sin sesgo sistemático, con forma aproximadamente gaussiana. Los errores más grandes se concentran en valores predichos bajos, lo que refleja la dificultad estructural de identificar y analizar estudiantes con nota real igual a cero (casos de abandono que ningún modelo consigue capturar completamente).

En cuanto al análisis de importancia de variables de la sección 10 del notebook 4, hemos empleado Lasso por su utlidad para identificar valores con mayor importancia al poner coeficientes a 0 (recordamos su forma de rombo). Los resultados nos confirman que el rendimiento del primer semestre

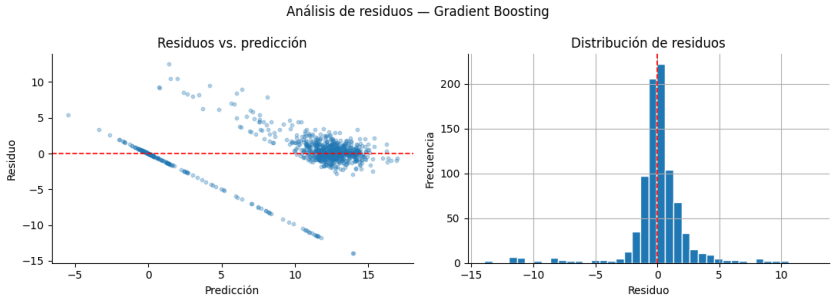


Figure 6: Análisis de residuos del mejor modelo (Gradient Boosting)

(especialmente las asignaturas aprobadas y la nota media) es el predictor más potente. Variables de acceso como `nota_admision` y `nota_cualificacion_previa` tienen un papel secundario pero relevante, lo que sugiere que el historial académico previo aporta información adicional más allá del primer semestre.

6 Tarea 3. Aprendizaje no supervisado: Clustering

El objetivo es identificar perfiles de estudiantes mediante técnicas no supervisadas, sin utilizar la variable objetivo como guía del análisis. Aplicamos tres familias de métodos: clustering particional (K-Means), jeráquico (AGNES) profundizadas en clase y, a modo de investigación adicional, basado en modelos (GMM).

6.1 Selección de variables

Trabajamos con el dataset comleto (sin split train/test) y un subconjunto de 10 variables interpretables y no redundantes: `nota_media_1sem`,`nota_media_2sem`, `nota_media_1sem_aprobadas`, `nota_media_2sem_aprobadas`, `nota_admision`, `nota_cualificacion_previa`, `edad_al_matricularse`, `matricula_al_dia`, `deudor`, `becado`. Excluímos variables macroeconómicas (no describen al individuo) y variables que estén muy correlacionadas entre sí. Todas las variables se estandarizan previamente con `StandardScaler`, paso imprescindibles para K-Means.

6.2 Reducción de dimensionalidad con PCA

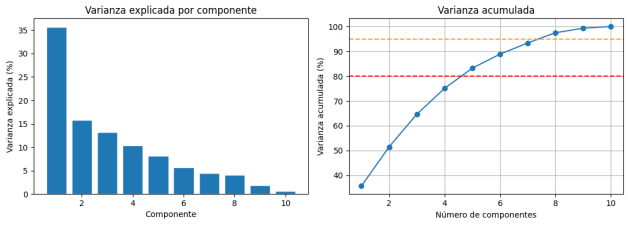


Figure 7: Varianza explicada por los componentes principales.

Aplicamos PCA sobre las 10 variables para analizar la varianza explicada. Como vemos en la figura, con 5 componentes se captura el 80% de la varianza; con 8 componentes, el 95%, lo que confirma que podemos representar gran parte de la información en dimensiones reducidas, lo cual nos será más cómodo. De hecho, los dos primeros componentes explican conjuntamente el 51.5% de la varianza total, suficiente para ver la estructura principal.

6.3 Elección del número de clusters

Evaluamos valores de k entre 2 y 8 mediante tres criterios complementarios: método del codo (inercia), índice de silueta (mayor es mejor) e índice de Dunn (mayor es mejor). Añadimos además la

conectividad como validación adicional, que mide en qué medida los vecinos más cercanos de cada punto pertenencen al mismo cluster (menor es mejor).



Figure 8: Criterios de selección del número de clusters.

El índice de silueta es máximo en $k = 2$, mientras qaue Dunn señala $k = 3$. Ante su discrepancia, optamos por $\mathbf{k = 3}$: el codo, Dunn y la conectividad convergen a este valor, y tres clusters ofrececen una interpretación más rica institucionalmente, nos permetiría distinguir un alto rendimiento, uno de riesgo y uno intermedio, encajando con la variable objetivo de aprendizaje supervisado.

6.4 Bloque 1: K-Means

Entrenamos K-Means con $k = 3$, obteniendo una silueta de 0.235 y un índice de Dunn de 0.030. El análisis de silueta individual confirma que solo 42 observaciones presentan $Si < 0$ y podrían estar mal asignadas, pero alrededor del 95% presenta una asignación correcta, con cierto solapamiento en el perfil intermedio.

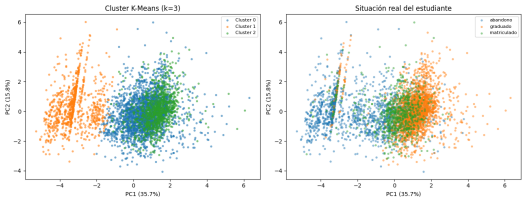


Figure 9: Proyección PCA 2D.

A la izquierda vemos el coloreado por K-means (cluster 1 bien separado y 0 y 2 más compactos) y a la derecha coloreado por situación real donde se alinean muy parecidamente con las clases objetivo sin haberlas utilizado en el training.

La proyección confirma que PC1 (35.7% de varianza) concentra la mayor discriminación entre perfiles. El Cluster 1 queda aislado y, junto al heatmap de la sección 8 del notebook 5, vemos que corresponde mayoritariamente a estudiantes en abandono: rendimiento cerca de cero en ambos semestres, mayor edad al matricularse y sin beca. Por otro lado, los clusters 0 y 2 se solapan en la zona derecha, al igual que graduados y matriculados en la situación real: Cluster 2 concentra el $\sim$85% de graduados y destaca por el valor de beca más extremo del análisis (1.74), mientras que Cluster 0 es el perfil mayoritario e intermedio con rendimiento sólido pero sin apoyo académico. Destaca además `nota_admision` y `nota_cualificacion_previa` presentan valores cercanos a cero en los tres clusters, reforzando el hallazgo de las tareas supervisadas: el rendimiento de la universidad es más determinante que el historial académico previo.

6.5 Bloque 2: Clustering Jerárquico (AGNES)

Comparamos los cuatro métodos de linkage estudiados. Single, por ejemplo, produce el efecto cadena que esperábamos: clustes muy desequilibrados donde muchas observaciones se van a un único grupo. Hemos comprobado que Ward es el que produce la estructura más interpretable, con tres ramas claramente diferenciadas y saltos de altura definidos en el dendrograma, coherente con su objetivo de minimizar la varianza intra-cluster en cada fusión, por lo que lo seleccionamos para el análisis.

Aplicando un corte en el dendrograma de Ward que genera $k = 3$, el resultado es prácticamente idéntico al de K-Means en el PCA; un cluster compacto negativo (perfil de abandono) y dos clusters solapados a la derecha. Esto demuestra la robustez de la distinción de los perfiles.

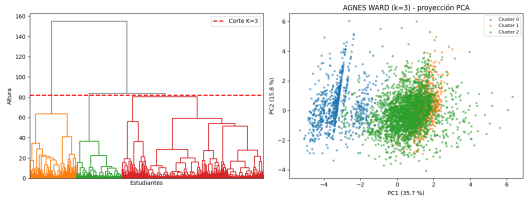


Figure 10: AGNES Ward con $k = 3$

A la izquierda vemos el dendrgrama con el corte en k=3; y a la derecha la proyección PCA, cuya estructura es prácticamente idéntica a K-Means.

6.6 Bloque 3: GMM

Investigando a cuenta personal en modo adicional, hemos implementado GMM, basado en asignar probabilidades de pertenencia a cada cluster. Sus criterios BIC y AIC no muestran un mínimo claro (ambos decrecen hasta k=8) pero sí uno más brusco, $k = 3$, lo cual sigue modelos anteriores.

Vemos una comparativa con el resto de modelos:

Table 3: Comparativa final de métodos de clustering ($k = 3$).

Método	**k**	**Silueta**	**Dunn**
K-Means	3	0.235	0.039
AGNES (ward)	3	0.195	0.064
GMM	3	**0.323**	**0.172**

GMM obtiene sin duda la mejor silueta y el mejor Dunn, haciéndolo el más óptimo. Los tres métodos convergeen en $k = 3$ e identifican la misma estructura: un **perfil de riesgo** (Cluster 1, con un 80% de abandono), un **perfil de éxito con beca** (Cluster 2, con un 85% de graduados) y **perfil intermedio** mayoritario (Cluster 0). La homogeneidad del perfil de riesgo es especialmente relevante: estos estudiantes presentan señales apreciables desde el primer semestre, potenciando intervenciones preventivas en el próximo primer semestre. Que estos perfiles surjan también aprendizaje no supervisado, refuerza su solidez como estructura real presente en los datos.

7 Discusión de resultados

Los resultados de las tres tareas concuerdan con nuestras hipótesis y son coherentes entre sí, apuntando a conclusines consitentes sobre los factores que determinan la trayectoria académica.

El rendimiento del primer semestre es el predictor dominante Tanto en clasificación como en regresión, las variables `nota_media_1sem` y `asignaturas_1sem_aprobadas` encabezan la importancia de features en todos los modelos. Clustering lo confirma. Esto sugiere que el primer semestre actúa como un filtro temprano: los estudiantes que no consolidan su rendimiento al principio del curso, tienen una probabilidad significativamente mayor de abandonar. Esta observación es accionable insitucionalmente, intervenciones en el primer semestre podrían tener mayor impacto que las realizadas posteriormente.

Las variables socioeconómicas tienen un papel secundario pero relevante. Variables como `matricula_al_dia`, `deudor` y `becado` contribuyen de forma consistente en los modelos y son determinantes en la identificación del perfil de riesgo del Cluster 1. Esto indica que las dificultades económicas se asocian con el abandono de forma independiente al rendimiento académico, lo que sugiere la necesidad de intervenciones diferenciadas según el tipo de riesgo. Por ello sugerimos institucionalmente distinguir entre riesgo académico del riesgo económico para orientar el apoyo óptimo.

La clase *matriculado* es inherentemente difícil de predecir. El F1 más bajo en clasificación corresponde sistemáticamente a esta clase,independientemente del modelo. Esta clase no representa

un perfil académico consolidado sino un estado transitorio, (estudiantes que aún no han completado ni abandano sus estudios), explicando su solapamiento con las otras dos clases en el espacio de features.

Limitaciones. En primer lugar, todo lo analizado y deducido es de naturalezca correlacional. Como sabemos, correlación no implica causalidad, y cualquier intervención institucional basada en estos modelos requeriría validación adicional. En segundo lugar, los datos provienen de una única institución portuguesa, lo que limita la generalización a otros contextos educativos. Finalmente, la alta proporción de ceros en `nota_media_2sem` (19.7%) introduce asimetría en la tarea de regresión que los modelos no capturan perfectamente.

8 Conclusión

Este trabajo ha abordado la predicción del éxito académico en educación superior desde tres perspectivas complementarias. Las principales conclusiones son:

- **Clasificación:** Gradient Boosting obtiene el mejor F1 macro (0.690), aunque los modelos lineales y de ensemble alcanzan resultados similares, indicando un rendimiento natural en el problema. El abandono y la graduación son predecibles con alta fiabilidad (AUC > 0.9); la clase *matriculado* es difícil de analizar al ser 'transitoria'.
- **Regresión:** Es posible anticipar la nota del segundo semestre con un R^2 de 0.74 y un RMSE de 2.63 puntos a partir exclusivamente de información previa. El rendimiento del primer semestre es el predictor más potente, con una aportación marginal de variables de acceso y contexto socieconómico.
- **Clustering:** Tres métodos independientes (K-Means, AGNES y GMM) convergen a k =3 e identifican la misma estructura: un **perfil de riesgo** (80% de abandono), un **perfil de éxito** (85% de graduados), y un **perfil intermedio mayoritario**. El perfil de riesgo es accionable institucionalmente y podría servir como base para sistemas de alerta temprana.

De igual manera, este proyecto ha sido enormemente enriquecedor para poner en situación y en práctica los conceptos estudiados en la asignatura, llevando las fórmulas teóricas a la realidad y a un contexto familiar como es el ámbito educativo.

9 Bibliografía

-Scikit-learn user guide: `https://scikit-learn.org/stable/user_guide.html`

-StatQuest with Josh Starmer, Youtube: `https://www.youtube.com/c/joshstarmer`

-Seaborn: statistical data visualization `https://seaborn.pydata.org`

-*An Introduction to Statistical Learning with Applications in Python*. G. James, D. Witten, T. Hastie. También documentación de python del libro: `https://intro-stat-learning.github.io/ISLP/`

-*Bishop- Pattern Recognition and Machine Learning*. C. M. -Matplotlib Documentation `https://matplotlib.org/stable/gallery/index.html`

-Herramienta de asistencia de corrección de errores y mejoras: OpenAI

ADRIANA LORENZO MINGORANCE. 2º B iMAT.